

UAX · GESTIÓN DE DATOS

Proyecto Final · 2025/26

Saleshealth

*Construcción de un entorno analítico
y cálculo de métricas relacionadas con el cliente*

A U T O R A

Judith M.^a Salas García

A S I G N A T U R A

Gestión de Datos · Data Management

S T A C K

PostgreSQL · Python 3.11 · Streamlit · Plotly

F E C H A

Mayo 2026

— RESUMEN EJECUTIVO

Saleshealth · entorno analítico para CLTV

El proyecto desarrolla un entorno analítico end-to-end para una empresa ficticia del sector de productos de salud y bienestar. La solución consolida 13 tablas operacionales (ERP, CRM, logística y postventa) en un Data Warehouse modelado según los principios de Kimball, calcula métricas de Customer Lifetime Value y aplica una segmentación K-Means con triple validación de K. La explotación se materializa en un dashboard Streamlit de cinco páginas.

El pipeline procesa 70 844 filas de origen (5 750 clientes, 20 000 pedidos, 42 555 líneas), genera 9,68 M € de revenue analizado y 3,87 M € de margen, y se ejecuta en aproximadamente 75 segundos sobre el dataset completo. Toda la lógica se versiona en Python 3.11 sobre PostgreSQL 15, con dependencias fijadas en requirements.txt para reproducibilidad.

La implementación va más allá del enunciado en tres aspectos: el CLTV no solo se calcula con la fórmula sencilla $AOV \times Frecuencia \times Vida\ útil$, sino también con un modelo probabilístico BG/NBD + Gamma-Gamma que proyecta a 12 meses; la elección del K combina tres métricas independientes (Elbow, Silhouette, Davies-Bouldin) en un score ponderado; y la dimensión geográfica se explota mediante un mapa interactivo de las 20 tiendas de Madrid.

. . .

— CAPÍTULO 1

Contexto y objetivos

El sector de productos de salud y bienestar, proyectado en 12 482 mil millones de USD para 2026 según Business Research Insights, atraviesa una fase de consolidación impulsada por la creciente conciencia del consumidor sobre su salud, la integración de tecnología wearable y la demanda de experiencias holísticas. En este escenario, la integración de datos dispersos en sistemas operacionales heterogéneos se convierte en un requisito imprescindible para tomar decisiones basadas en evidencia.

El proyecto responde a esta necesidad mediante el diseño e implementación de un Data Warehouse centralizado que cumple cuatro objetivos: (i) consolidar la información de cuatro áreas funcionales en una arquitectura escalable; (ii) garantizar la calidad de los datos mediante un proceso de validación declarativa; (iii) calcular el valor económico de cada cliente con dos aproximaciones complementarias; y (iv) ofrecer una segmentación accionable para campañas de retención. El alcance cubre los seis entregables exigidos por el enunciado y añade tres extensiones (CLTV probabilístico, triple validación de K y análisis geográfico) sin desviar el foco del problema central.

— CAPÍTULO 2

Identificación de fuentes y modelo Entidad-Relación

El sistema de origen integra 13 tablas distribuidas en cuatro áreas funcionales: ERP (catálogo y transacciones), CRM (identidad del cliente), logística (red de tiendas y geografía) y postventa (devoluciones). El modelo refleja una estructura normalizada propia de un sistema operacional, con catálogo separado de transacciones y una doble jerarquía de producto: cada product local pertenece a un central_product que referencia a brand y category, permitiendo catálogos locales con variantes regionales sobre un producto maestro.

Es crítica la distinción entre las dos tablas transaccionales: sale agrupa varias líneas en un único pedido, mientras que sale_item es el grano más fino del modelo (una fila por línea de venta). Esta separación se preserva en el DWH y resulta fundamental para calcular correctamente la frecuencia de compra y el ticket medio en el módulo de CLTV.




Figura · Modelo Entidad-Relación de la base de datos de origen — 13 tablas distribuidas en ERP (catálogo + transacciones), CRM (customer), logística (store + city_zone) y postventa (return_item + return_reason).

— CAPÍTULO 3

Modelo dimensional

El Data Warehouse implementa un esquema en estrella organizado en tres capas: stg para staging (réplica 1:1 del origen tras la extracción), dwh para el modelo dimensional propiamente dicho (4 dimensiones + 2 hechos con surrogate keys) y marts para tablas analíticas precomputadas (CLTV y segmentación). Esta separación medallion permite reprocesos parciales sin tocar el origen y desacopla el dashboard del coste de cómputo del clustering.




Figura · Modelo dimensional · 4 dimensiones (dim_customer, dim_product, dim_location, dim_date) + 2 hechos (fact_sales con grano de línea de venta, fact_returns) + 2 marts analíticos.

DECISIONES DE DISEÑO

- **Surrogate keys** — cada dimensión usa una clave entera autoincremental independiente del identificador de origen, desacoplando el DWH de los sistemas operacionales y permitiendo aplicar Slowly Changing Dimensions en futuras evoluciones.
- **Grano máximo en fact_sales** — una fila por sale_item. Preserva el detalle y permite agregaciones flexibles a nivel de pedido, cliente, producto, tienda o fecha.
- **Imputación de costes** — cuando un producto carece de unit_cost en origen, se imputa con la media de su categoría y se marca con cost_was_imputed=TRUE para trazabilidad.
- **dim_date sintética** — calendario completo (>2 900 fechas) con atributos derivados (year, quarter, year_month, is_weekend) para análisis temporales sin recalcular.
- **Tablas marts precomputadas** — customer_lifetime_value y customer_segments evitan recalcular en cada carga del dashboard, llevando los tiempos de respuesta por debajo de 1 segundo.

— CAPÍTULO 4

Arquitectura del ETL

El pipeline se estructura en siete fases secuenciales, todas idempotentes y orquestadas mediante un único punto de entrada (run.py) que admite ejecución parcial o completa. La ejecución end-to-end sobre el dataset de 5 750 clientes y 42 555 ventas tarda aproximadamente 75 segundos en una máquina de desarrollo estándar.




Figura · Flujo del ETL — siete fases que mueven los datos del origen al dashboard, con un proceso transversal de validación que aborta el pipeline ante errores críticos.

- **bootstrap** — recrea la BD destino y aplica el DDL completo (3 schemas, 8 tablas dimensionales y de hechos, índices y comentarios).
- **extract** — replica las 13 tablas de origen al schema stg mediante COPY FROM streaming. 70 844 filas en aproximadamente 4 segundos.
- **transform_dimensions y transform_facts** — pueblan las 4 dimensiones y los 2 hechos a partir de stg, calculando net_amount, margin_amount y enlazando claves dimensionales.
- **validate** — ejecuta 20 checks declarativos de calidad. El pipeline aborta si un check con severity=error falla; los warnings solo registran aviso.
- **cltv** — calcula los tres CLTV (histórico, simple del enunciado, predictivo a 12 meses) y poble marts.customer_lifetime_value.
- **cluster** — aplica StandardScaler, PCA preservando 95 % de varianza, evalúa K = 2..10 con tres métricas, entrena K-Means con el K óptimo y proyecta UMAP 2D.

— CAPÍTULO 5

Validación de calidad

Antes de exponer cualquier métrica al dashboard, el ETL ejecuta una batería declarativa de 20 checks SQL agrupados en cuatro categorías. Cada check devuelve una pareja (actual, expected): si difieren y la severity es error, el pipeline aborta con exit code 1; si la severity es warning, solo se registra el incidente. La política conservadora garantiza que el modelo dimensional nunca se publica con inconsistencias estructurales.

Los counts verifican que no se pierde información en el camino stg → dwh. Los checks de integrity comprueban que no hay claves huérfanas tras la asignación de surrogate keys. Las reglas de business validan invariantes del negocio (cantidades positivas, fechas coherentes). Los checks de consistency aseguran la coherencia entre flags y hechos.

CATÁLOGO COMPLETO DE CHECKS

Categoría	Check	Tipo
Counts	dim_date contiene calendario completo (> 2 900 filas)	error
Counts	dim_customer no está vacía	error
Counts	dim_product no está vacía	error
Counts	dim_location no está vacía	error
Counts	fact_sales contiene ventas	error
Counts	fact_returns contiene devoluciones	error
Counts	dim_customer = stg.customer (sin pérdida)	error
Counts	dim_product = stg.product (sin pérdida)	error
Counts	fact_sales = stg.sale_item (sin pérdida)	error
Counts	fact_returns = stg.return_item (sin pérdida)	error
Integrity	0 huérfanas customer_key en fact_sales	error
Integrity	0 huérfanas product_key en fact_sales	error
Integrity	0 huérfanas date_key en fact_sales	error
Business	0 ventas con quantity $\leq$ 0	error
Business	0 ventas con net_amount negativo	error
Business	0 devoluciones sin venta correspondiente	error
Business	days_to_return $\geq$ 0 en todas las devoluciones	error
Consistency	is_returned coincide con existencia en fact_returns	error
Consistency	< 30 % de productos con coste imputado	warning
Consistency	Tasa global de devolución < 15 %	warning

— CAPÍTULO 6

Cálculo del CLTV

El cálculo del Customer Lifetime Value se implementa siguiendo dos aproximaciones complementarias que se persisten en `marts.customer_lifetime_value`: una determinista que responde directamente al requisito del enunciado, y una probabilística que añade rigor estadístico y proyección a futuro. Ambas conviven en la misma fila por cliente, permitiendo al usuario del dashboard alternar entre ellas según el caso de uso.

CLTV SIMPLE · FÓRMULA DEL ENUNCIADO

Conforme a la fórmula $CLTV = \text{Ingresos} \times \text{Margen} \times \text{Frecuencia} \times R$ indicada en el caso de uso, se calcula el valor histórico de cada cliente como $AOV \times \text{frecuencia_anual} \times \text{vida_útil_años}$, donde AOV es el ticket medio histórico, la frecuencia anual se deriva del número de pedidos entre el rango de actividad observado, y la vida útil se mide en años desde la primera hasta la última compra. Este cálculo se persiste en la columna `cltv_simple`.

CLTV PROBABILÍSTICO · BG/NBD + GAMMA-GAMMA

Como complemento al cálculo determinista, se entrena un modelo probabilístico estándar de industria, originalmente desarrollado por Fader y Hardie (2005), que combina dos sub-modelos: BG/NBD (Beta-Geometric / Negative Binomial Distribution) estima el número esperado de compras en los próximos 12 meses condicionado al historial de cada cliente, así como la probabilidad de que el cliente siga activo (`alive_probability`); y Gamma-Gamma estima el valor monetario esperado por transacción futura, asumiendo independencia entre frecuencia y valor — asunción que se valida calculando la correlación de Pearson entre ambas series.

El CLTV proyectado a 12 meses se obtiene combinando ambos modelos con una tasa de descuento del 1 % mensual, equivalente al WACC habitual del sector retail. La implementación de `etl/cltv.py` incluye una estrategia de robustez doble: (i) reintentos con cinco coeficientes de penalización progresivos (0,001 → 10) ante errores de convergencia del optimizador; y (ii) un fallback heurístico que aproxima `alive_probability` como $(1 - \text{recency}/T)$ y proyecta compras futuras extrapolando la frecuencia histórica, asegurando que el pipeline siempre complete con éxito independientemente de la calidad estadística de los datos.

RESULTADOS

El análisis revela una distribución consistente con el principio de Pareto: 742 clientes (12,9 % de la base) clasificados como Champions concentran el 99,6 % del CLTV proyectado a 12 meses (1,33 M € sobre 1,34 M € totales), frente al 0,4 % aportado por los 5 008 clientes restantes. Esta concentración extrema se explica por la composición del dataset: los Champions tienen `alive_probability` media de 1,00 y una expectativa de 5,2 compras/año, mientras que el segundo cluster muestra una media de 1,0 pedidos históricos.

— CAPÍTULO 7

PCA y selección rigurosa de K

La segmentación parte de un vector de 8 features por cliente extraído de `marts.customer_lifetime_value`: `num_orders`, `num_units`, `revenue_total`, `margin_total`, `avg_order_value`, `alive_probability`, `expected_purchases_12m` y `cltv_predicted_12m`. Sobre este espacio se aplica `StandardScaler` para igualar varianzas, seguido de PCA conservando el 95 % de la varianza acumulada, antes de entrenar el clustering. La estandarización es imprescindible porque el `revenue` (en miles de €) dominaría a la `alive_probability` (en 0..1) sin esa transformación.

TRIPLE VALIDACIÓN DE K

La elección del número de clusters combina tres métricas que abordan el problema desde ángulos distintos: el método del codo sobre la inercia intra-cluster (cuanto menor mejor, pero penalizando ganancias marginales que se aplanan), el coeficiente de silueta que mide la separación entre clusters en $[-1, 1]$ (cuanto mayor mejor) y el índice Davies-Bouldin que cuantifica el solapamiento (cuanto menor mejor). El K óptimo se elige con un score ponderado: $0,5 \text{ silhouette} + 0,3 (1 - \text{Davies-Bouldin}) + 0,2 \text{ elbow}$. Las tres métricas convergen en $K = 2$ sin necesidad de inspección visual ad hoc.

K	Inercia	Silhouette ↑	Davies-Bouldin ↓	Decisión
2	7 762,80	0,8378	0,2996	óptimo
3	4 258,67	0,6882	0,4916	—
4	2 917,29	0,6612	0,6042	—
5	1 772,11	0,6535	0,5232	—
6	1 354,35	0,6009	0,5326	—
7	975,46	0,5983	0,5363	—
8	815,47	0,6032	0,5473	—
9	677,87	0,5943	0,5792	—
10	559,14	0,6066	0,5488	—

Con $K=2$, el coeficiente de silueta de 0,838 indica una separación excelente (valores $> 0,7$ son raros en datos reales) y el Davies-Bouldin de 0,300 confirma un solapamiento muy bajo. Aumentar K a 3 ya degrada significativamente ambas métricas, lo que sugiere que el dataset tiene una estructura genuinamente bimodal.

— CAPÍTULO 8

Resultado de la segmentación

La segmentación final asigna 742 clientes (12,9 %) al cluster Champions y 5 008 (87,1 %) al cluster En riesgo de churn. Para representar la separación se ofrecen dos proyecciones 2D: PCA preserva la varianza global mientras que UMAP preserva la estructura local de vecindarios. UMAP no es exigido pero aporta una visualización más informativa al respetar la topología del espacio original; en este caso ambas proyecciones muestran los Champions agrupados en una región compacta y separada del resto.

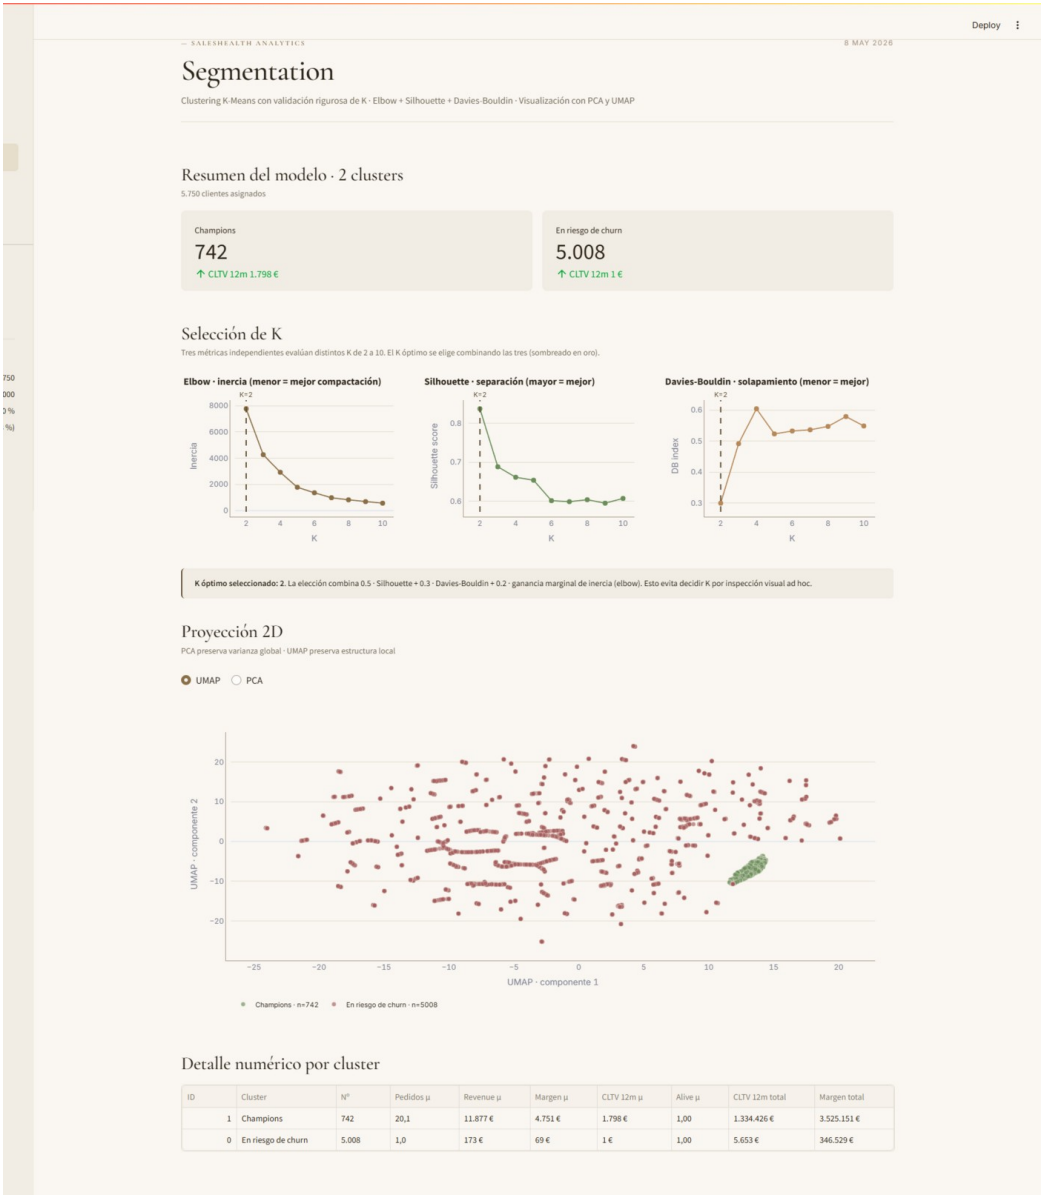


Figura · Página de Segmentation del dashboard — KPIs de los dos clusters, triple validación de K (Elbow + Silhouette + Davies-Bouldin con K=2 sombreado), proyección UMAP 2D y detalle numérico por cluster.

— CAPÍTULO 9

Dashboard ejecutivo

La explotación del modelo se materializa en un dashboard interactivo desarrollado en Streamlit 1.40, organizado en cinco páginas. La estética sigue una paleta neutra de tonos beige y marrón inspirada en el diseño editorial, con tipografía serif (Cormorant Garamond) para titulares y sans-serif tabular (Inter) para cifras. Los gráficos se construyen con Plotly y se cachean con `@st.cache_data` para garantizar tiempos de respuesta por debajo de un segundo.

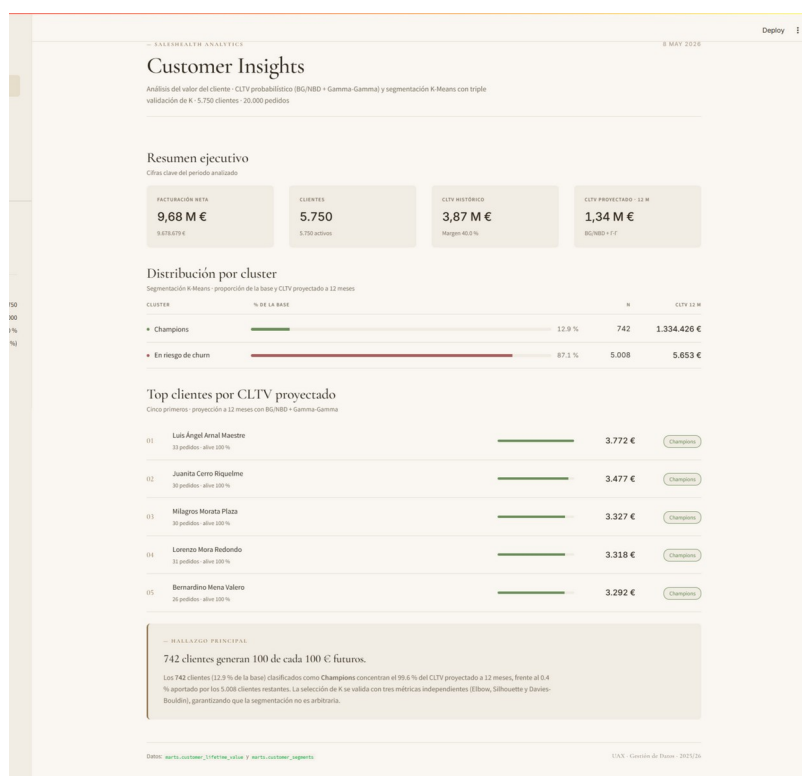


Figura · Página principal del dashboard — KPIs ejecutivos (facturación, CLTV agregado), distribución por cluster con barras horizontales, top 5 de clientes por CLTV proyectado y hallazgo automático destacado.

- **Home** — snapshot ejecutivo con los cuatro KPIs principales, distribución por cluster y top 5 de clientes.
- **Customer Value** — evolución mensual de revenue y margen, distribución del CLTV proyectado y curva de Pareto del 80/20.
- **Segmentation** — triple validación de K, scatter PCA/UMAP coloreado por cluster y perfil estadístico por cluster.
- **Customer Detail** — ficha individual con timeline de pedidos, posición percentil y detalle por línea.
- **Stores Map** — mapa Mapbox de las 20 tiendas con tamaño proporcional al revenue, ranking y hallazgo de concentración.

HALLAZGOS DEL ANÁLISIS GEOGRÁFICO

El revenue por tienda oscila entre los 436 314 € (Store Chamberí) y los 549 653 € (Store Sol), un rango relativo del 26 % que indica una red bastante homogénea. Las tres tiendas líderes (Sol, Salamanca, Retiro) concentran 1,61 M € de los 9,68 M € totales, equivalente al 17 % del revenue. El margen porcentual es prácticamente idéntico (40,0 %) en las 20 tiendas, lo que sugiere que la política de precios y el mix de producto son uniformes a nivel de red — y abre la oportunidad de introducir mix diferenciado por distrito (premium en centro, volumen en periferia) para capturar elasticidades distintas sin incrementar costes.

— CAPÍTULO 10

Conclusiones y líneas de mejora

El proyecto cumple los seis entregables del enunciado y añade tres extensiones que enriquecen la solución sin desviar el foco del problema central. El CLTV probabilístico complementa la fórmula sencilla con una proyección a futuro fundamentada estadísticamente y una probabilidad de churn por cliente. La triple validación del clustering aporta rigor a la elección de K usando tres métricas independientes en lugar de una. El análisis geográfico explota la dimensión de localización aportando insights sobre la heterogeneidad de la red de 20 tiendas de Madrid.

APRENDIZAJES

Tres aprendizajes merecen reflexión específica. En primer lugar, la importancia de validar los datos antes de modelar: los 20 checks de calidad detectaron tempranamente inconsistencias estructurales (huérfanas, costes ausentes) que habrían propagado errores al cálculo del CLTV. En segundo lugar, la conveniencia de la separación `stg` → `dwh` → `marts` no solo por elegancia arquitectónica sino por rendimiento: precomputar el CLTV en `marts` permite que el dashboard responda en menos de un segundo incluso sobre 5 750 clientes, y abre la puerta a estrategias incrementales sin tocar el `dwh`. En tercer lugar, la diferencia entre rigor matemático y utilidad de negocio: el dashboard incluye visualizaciones explicativas (curva de Pareto, hallazgo automático) que facilitan la interpretación incluso para usuarios sin formación técnica, sin sacrificar la calidad analítica subyacente.

LÍNEAS DE MEJORA FUTURAS

- Incorporar un análisis de cesta de la compra (Market Basket Analysis con algoritmo Apriori o FP-Growth) para identificar oportunidades de venta cruzada por categoría de producto.
- Sustituir el cálculo batch del CLTV por un proceso incremental que se actualice tras cada nuevo pedido, aplicando el patrón “lambda architecture” con una capa speed sobre Redis.
- Pseudonimizar los nombres de cliente en `dim_customer` mediante un hash determinista, cumpliendo con principios de privacidad por diseño y permitiendo entornos de desarrollo sin datos personales.
- Migrar el cálculo de cluster a Dask o Spark si el volumen de clientes supera el millón, manteniendo la triple validación de K como criterio de elección.

— REFERENCIAS

Bibliografía

LIBROS Y ARTÍCULOS ACADÉMICOS

- Davies, D. L. & Bouldin, D. W. (1979). A Cluster Separation Measure. IEEE Transactions on Pattern Analysis and Machine Intelligence, 1(2), 224-227.
- Fader, P. S. & Hardie, B. G. S. (2013). The Gamma-Gamma Model of Monetary Value. Bruce Hardie's Notes.
- Fader, P. S., Hardie, B. G. S. & Lee, K. L. (2005). "Counting Your Customers" the Easy Way: An Alternative to the Pareto/NBD Model. Marketing Science, 24(2), 275-284.
- Kimball, R. & Ross, M. (2013). The Data Warehouse Toolkit: The Definitive Guide to Dimensional Modeling. Wiley, 3rd ed.
- McInnes, L., Healy, J. & Melville, J. (2018). UMAP: Uniform Manifold Approximation and Projection for Dimension Reduction. ArXiv:1802.03426.
- Rousseeuw, P. J. (1987). Silhouettes: a graphical aid to the interpretation and validation of cluster analysis. Journal of Computational and Applied Mathematics, 20, 53-65.

DOCUMENTACIÓN TÉCNICA Y DE PRODUCTO

- Lifetimes Documentation (2024). Probabilistic Customer Lifetime Value Models in Python. <https://lifetimes.readthedocs.io/>
- PostgreSQL Global Development Group (2024). PostgreSQL 15 Documentation · Schemas and COPY. <https://www.postgresql.org/docs/15/>
- scikit-learn Developers (2024). User Guide · sklearn.cluster.KMeans, sklearn.decomposition.PCA. <https://scikit-learn.org/stable/>
- Streamlit Inc. (2024). Streamlit Documentation · Multipage Apps and Caching. <https://docs.streamlit.io/>

FUENTES SECTORIALES

- Business Research Insights (2024). Health and Wellness Products Market Report. <https://www.businessresearchinsights.com/market-reports/health-and-wellness-products-market-118977>
- Universidad Alfonso X el Sabio (2026). Proyecto Final · Gestión de Datos – Data Management. Material docente del curso 2025/26.